

ZADANIA MODELOWANIA



Jaki jest typ zadania/zadań?
Dla jakich danych generowane są predykcje?
Jakie są możliwe wyniki predykcji?
Kiedy obserwowane są wyniki (etykiety)?

Typ zadania: Klasyfikacja binarna (czy pobyt będzie długi?) oraz analiza istotności cech (Feature Importance) w celu identyfikacji „kryteriów”.

Dane wejściowe: Cechy przeglądanych lokali, parametry sesji (np. liczba osób), historia użytkownika.

Wyniki: Prawdopodobieństwo długiego pobytu oraz lista atrybutów, które o tym zadecydowały.

Etykiety: Wyliczone jako różnica między booking_duration a booking_date (sukces = pobyt powyżej przyjętego progu, np. 7 dni).

DECYZJE



Jak predykcje przekształcane są w konkretne rekomendacje lub zmiany dla użytkownika końcowego?

Działanie: Jeśli model zidentyfikuje wysoką szansę na długi pobyt, system wyświetli konsultantowi sugestię: „Klient priorytetowy – zaproponuj lokale z [Top Kryterium, np. kuchnią]”.

Zmiana dla użytkownika: Konsultant może proaktywnie skontaktować się z klientem z ofertą skrojoną pod jego specyficzne potrzeby długoterminowe.

PROPOZYCJA WARTOŚCI



Kto jest ostatecznym beneficjentem i jakie konkretne problemy są rozwiązywane?
Jak system uczenia maszynowego zostanie zintegrowany z istniejącym rozwiązaniem?

Kto jest beneficjentem? Konsultanci serwisu Nocarz oraz dział sprzedaży.

Problemy: Brak wiedzy o tym, jakie cechy lokali decydują o wyborze długiego pobytu, co utrudnia skuteczne doradztwo.

Cel: Dostarczenie rankingu cech (kryteriów) najważniejszych dla klienta długoterminowego, co pozwoli na lepszą personalizację ofert i wzrost konwersji rezerwacji

ZBIERANIE DANYCH



Jakie strategie stosowane są do aktualizacji danych po wdrożeniu?

Strategia: Logowanie wszystkich sesji zakończonych rezerwacją do nowej tabeli treningowej.

Feedback: Zbieranie informacji od konsultantów, czy rekomendacja modelu była trafna w rozmowie z klientem.

ŹRÓDŁA DANYCH



Jakie źródła danych będą potrzebne do skonstruowania wstępnego zbioru danych uczących?
Jak zdefiniowane będą etykiety?

Pliki: listings.csv, sessions.csv, users.csv. (Zbiór jest w 100% wystarczający do zbudowania skutecznego modelu).

Wnioskowane dane (jako opcja rozwoju w przyszłości): Kalendarz cen (zniżki) oraz filtry wyszukiwania z sesji.

Etykiety: Wyliczone jako różnica między booking_duration a booking_date.

WPŁYW PROJEKTU



Jakie są wartości kosztów/zysków dla (nie)poprawnych decyzji?
Jakie dane są używane do symulacji wpływu przed wdrożeniem?
Jakie są kryteria sukcesu?

Kryteria sukcesu:

Biznesowe: Wzrost średniej długości rezerwacji o 10% w skali kwartału.

Analityczne (Jakość predykcji): Osiągnięcie wartości metryki ROC AUC ≥ 0.75 oraz Average Precision (AP) wyższej niż dla modelu bazowego. Używamy tych metryk, ponieważ są one odporne na niezbilansowanie danych (klasa pozytywna stanowi ok. 33%).

GENEROWANIE PREDYKCJI



Czy predykcje generowane są wsadowo (batch) czy w czasie rzeczywistym?
Jak często?
Ile czasu jest dostępne na generowanie predykcji?

Tryb: Czas rzeczywisty (Online).

Częstotliwość: Predykcja odświeżana po każdej akcji view_listing w sesji.

Czas: Wynik dostępny dla konsultanta w mniej niż 1 sekundę od akcji klienta.

BUDOWANIE MODELI



Ile modeli jest potrzebnych na środowisku produkcyjnym?
Kiedy powinny być aktualizowane?
Ile czasu jest dostępne na to (włącznie z wyznaczaniem atrybutów i analizą)?

Liczba modeli: 1 model główny (np. XGBoost) oraz prosty model bazowy (Baseline) do porównania wyników.

Aktualizacja: Raz w miesiącu, aby uwzględnić sezonowe zmiany w kryteriach wyboru (np. inne priorytety zimą niż latem).

ATRYBUTY



Jakie reprezentacje encji są używane w czasie generowania predykcji?
Jakie agregacje lub transformacje są stosowane do surowych źródeł danych?

Lokal: room_type, accommodates, amenities (szczególnie: kuchnia, pralka, Wi-Fi), cena bazowa.

Użytkownik: Dotychczasowa średnia długość pobytu, cel podróży (prywatny/biznesowy - jeśli zostanie wynioskowany).

Kontekst: Wyprzedzenie rezerwacji (lead time), sezonowość, typ urządzenia.

Analityczne (Wyjaśnialność): Poprawne wygenerowanie rankingu SHAP (Top 3 kluczowych cech) dla 100% zidentyfikowanych długich pobyków. Koszty błędów: False Positive: Konsultant oferuje zniżki długoterminowe osobie, która ich nie potrzebuje (strata czasu). False Negative: Utrata klienta premium przez brak odpowiedniego dopasowania oferty.				
	MONITOROWANIE  Jakie metryki i KPI są używane do śledzenia wpływu systemu uczenia maszynowego po wdrożeniu, zarówno dla użytkowników końcowych, jak i dla biznesu? Jak często powinny być przeglądane? Metryki: Precyzja modelu w czasie, wskaźnik konwersji (CR) dla rekomendowanych ofert. Częstotliwość przeglądu: Cotygodniowe raporty techniczne oraz comiesięczne podsumowanie wpływu biznesowego.			



Dokument jest utworzony na podstawie: OWNML MACHINE LEARNING CANVAS v 1.2. Created by Louis Dorard, Ph.D. Licensed under a [Creative Commons Attribution-ShareAlike 4.0 International License](#).

OWNML.CO